


Item-to-item рекомендации похожих товаров для Ozon Fresh

Построение pipeline, который для каждого item_id выдаёт **top-K**
похожих товаров на основе пользовательского поведения. Основной
подход — **co-visitation graph**.

1



Made with GAMMA

Зачем нужны item-to-item рекомендации

Масштаб и скорость

Стабильные
рекомендации по
большому каталогу Ozon
Fresh — офлайн-
построение, быстрый
ответ

Быстрая замена

Пользователь находит
альтернативу или
дополнение к
выбранному товару без
лишних кликов

Длинный хвост

Работаем не только с
популярными товарами,
но и с редкими — через
fallback-стратегии

Измеримое качество


Оцениваем не «на глаз»,
а через строгую offline-
валидацию с временным
разделением данных

Почему co-visitation graph — хороший вариант

Товары считаются похожими, если пользователи взаимодействовали с ними в одних сессиях. Подход опирается на реальные поведенческие связи, интерпретируем, быстро строится офлайн через простые агрегации и хорошо подходит для товарных рекомендаций в Ozon Fresh.

Подход	Плюсы	Минусы
Same category	Просто и стабильно	Слишком грубые рекомендации
Content-based	Работает для cold start	Не ловит поведенческие связи
Co-visitation	Реальные связи товаров	Нужна фильтрация шума
Item2Vec / SASRec	Потенциально сильнее	Сложнее, дольше, требует больше данных и вычислений

Как устроен pipeline



Полный цикл от сырых событий до готовых рекомендаций занимает несколько часов офлайн. Fallback-каскад добивает товары, для которых поведенческий граф не дал достаточно кандидатов.

Как мы проверяли качество


Данные делим по времени на **train window** и **validation window**.

На **train** строим рекомендации, на **validation** сравниваем их с будущими связями товаров — это наш **ground truth**.

Основные ranking-метрики считаем по сильным действиям: `click`, `favorite`, `to_cart`.



Важно: пары только с просмотрами не должны завышать MRR/NDCG. View используем для диагностики, но не считаем основным сильным сигналом.



Метрики: качество, покрытие и безопасность

Business

`to_cart_hit_rate@K`, `to_cart_recall` — ловим будущие корзины, главная бизнесовая метрика

Ranking

`strong_ndcg@K`, `strong_mrr@K` — хорошие товары должны быть выше в выдаче

Coverage

`coverage@K`, `empty_share` — не оставлять товары без рекомендаций

Bias & Fallback

`popularity_bias@K`, `fallback_share` — контроль popular-only выдачи и добивки

Гипотеза 1: действия имеют разную ценность

Гипотеза

Не все действия пользователя одинаково важны. View показывает слабый интерес, click — явный интерес, favorite — сильную заинтересованность, to_cart — самый близкий к покупке сигнал.


Как проверяли

В scorer-е подбирали веса для разных типов действий и сравнивали качество рекомендаций по будущим сильным действиям: click, favorite, to_cart.

$$\begin{aligned} \text{score} = & 0.5 \cdot \text{view_count} \\ & + 1.5 \cdot \text{click_count} \\ & + 3.0 \cdot \text{favorite_count} \\ & + 4.0 \cdot \text{to_cart_count} \end{aligned}$$

Вывод

Лучшие веса не занулили view: он даёт массовую статистику. Но click, favorite и to_cart получили больший вес, потому что лучше отражают намерение пользователя.



Гипотеза 2: log/sqrt могут улучшить устойчивость

Гипотеза



Частые co-visitation пары могут доминировать в выдаче. Если сжать силу через `log` или `sqrt`, модель станет устойчивее и меньше будет зависеть от популярных товаров.

Как проверяли

Сравнили три варианта `count_transform` при tuning scorer-a:

- `linear`: используем count как есть;
- `sqrt`: мягко сжимаем большие counts;
- `log`: сильно сжимаем большие counts.

Результат




Вывод

На текущей validation-выборке `linear` оказался лучшим. Частота совместных действий товаров — не только bias, но и полезный behavioral-сигнал.

Гипотеза 3: frequency boost для редких действий

Effect of frequency boost beta on quality



Лучшее качество достигается без frequency boost: **beta = 0**.

Гипотеза

Редкие, но более сильные действия (favorite, to_cart) можно дополнительно усилить через параметр beta.

Что проверяли

Меняли beta в scoring-модели:

- beta = 0 — только business weights;
- beta > 0 — дополнительный boost для редких действий.

Результат

Лучшее качество получилось при beta = 0: best_hit = 0.7908, best_ndcg = 0.4400. При увеличении beta качество не улучшилось.

Вывод


Автоматическое усиление редких событий не помогло. Скорее всего, business weights уже достаточно хорошо задают важность действий, а дополнительный frequency boost переусиливает редкие сигналы и добавляет шум.

Гипотеза 4: fallback помогает редким товарам

Ключевая идея: behavioral co-visitation graph не всегда набирает полный top-K, особенно для редких товаров. Fallback добивает неполные выдачи через каскад от наиболее релевантных metadata-кандидатов к более общим.

- Основные рекомендации всегда из behavioral co-visitation
- Fallback только добивает неполный top-K
- Каскад идёт от точных кандидатов к общим
- Global popular — только последний уровень

Уровень	Зачем	Риск
category + type	Самые близкие metadata-кандидаты	Может не хватить
category	Расширяет coverage	Менее точно
type	При неполной категории	Смешивает товары
brand	Иногда полезен для заменителей	Не всегда похожи
global popular	Последний резерв	Очень рисково!




Гипотеза 5: popularity normalization

Гипотеза: популярные товары могут доминировать в рекомендациях, поэтому их можно штрафовать через popularity penalty.

Механизм: чем выше популярность source/candidate товара, тем сильнее уменьшается итоговый score.

Результат: мягкая нормализация почти не меняет качество, сильная — снижает hit/NDCG и резко увеличивает fallback_share.

Вывод: популярность оказалась не только bias, но и полезным behavioral-сигналом. Финально: normalization OFF.



С ростом power behavioral scorer теряет сильных кандидатов, и выдача всё чаще добивается fallback-слоем.

Отложенные гипотезы

Гипотеза	Статус	Почему отложили
Контекст виджета может влиять на качество сигнала	не успели проверить	может учитывать разную ценность действий из поиска, карточки товара, каталога и рекомендаций
Близость товаров внутри сессии может усиливать связь	пока без заметного прироста	текущие сессии короткие, поэтому расстояние между товарами внутри сессии даёт мало дополнительного сигнала
Более свежие связи могут быть важнее старых	не проверен полноценно	быстрые эксперименты были на маленьком окне, поэтому эффект свежести почти не проявляется

Future work

- Другие источники сигналов
- Персонализация
- Дальнейшая оптимизация реализации
- Проверить оставшиеся гипотезы



Что удалось сделать

- Разбили действия пользователей на сессии и построили co-visitation graph товаров.
- Настроили offline-валидацию через train / validation split и strong-метрики.
- Проверили несколько гипотез.
- Подготовили demo UI для просмотра рекомендаций и проверки результата на конкретных товарах.

Итог: получился воспроизводимый pipeline, который можно запускать офлайн и использовать как основу для блока “Похожие товары”.

14

